群測感知技術與應用

日期：2026/05/05

講者： 胡誌麟 教授

Mobile Crowd Sensing

> 💡 **MCS** 是一種利用大量行動使用者裝置來蒐集、感測、分析資料的系統。

現代使用者裝置具備多種能力，包括：

- 感測 sensing
- 運算 computing
- 儲存 storage
- 網路通訊 networking

常見裝置包括：

- 手機
- 穿戴式裝置
- 車載裝置 OBU, On-Board Unit
- IoT 裝置

MCS 的應用場景

1. **交通監控 Traffic Monitoring**
   例如利用手機或車輛感測資料分析車流、壅塞情況。
2. **物流追蹤 Logistics Tracking**
   透過行動裝置或車載裝置追蹤貨物與運輸路徑。

3. **社交互動 Social Interaction**
   分析使用者之間的互動行為與社群關係。
4. **疫情疾病監控 Epidemic Disease Monitoring**
   蒐集位置或健康相關資料，用於疫情追蹤與疾病監測。
5. **物件辨識 Things Identification**
   結合 IoT 或感測裝置辨識周遭物件。
6. **環境監控 Environment Monitoring**
   例如空氣品質、噪音、溫度、濕度等資料蒐集。
7. **災害回報 Reporting from Disaster Situations**
   災害發生時，由使用者回報現場狀況。
8. **特殊應用 Special Applications**
   例如智慧城市、工業應用、公共安全等。
9. **都市動態探勘 Urban Dynamic Mining**
   分析城市中人流、車流、活動模式等動態資料。

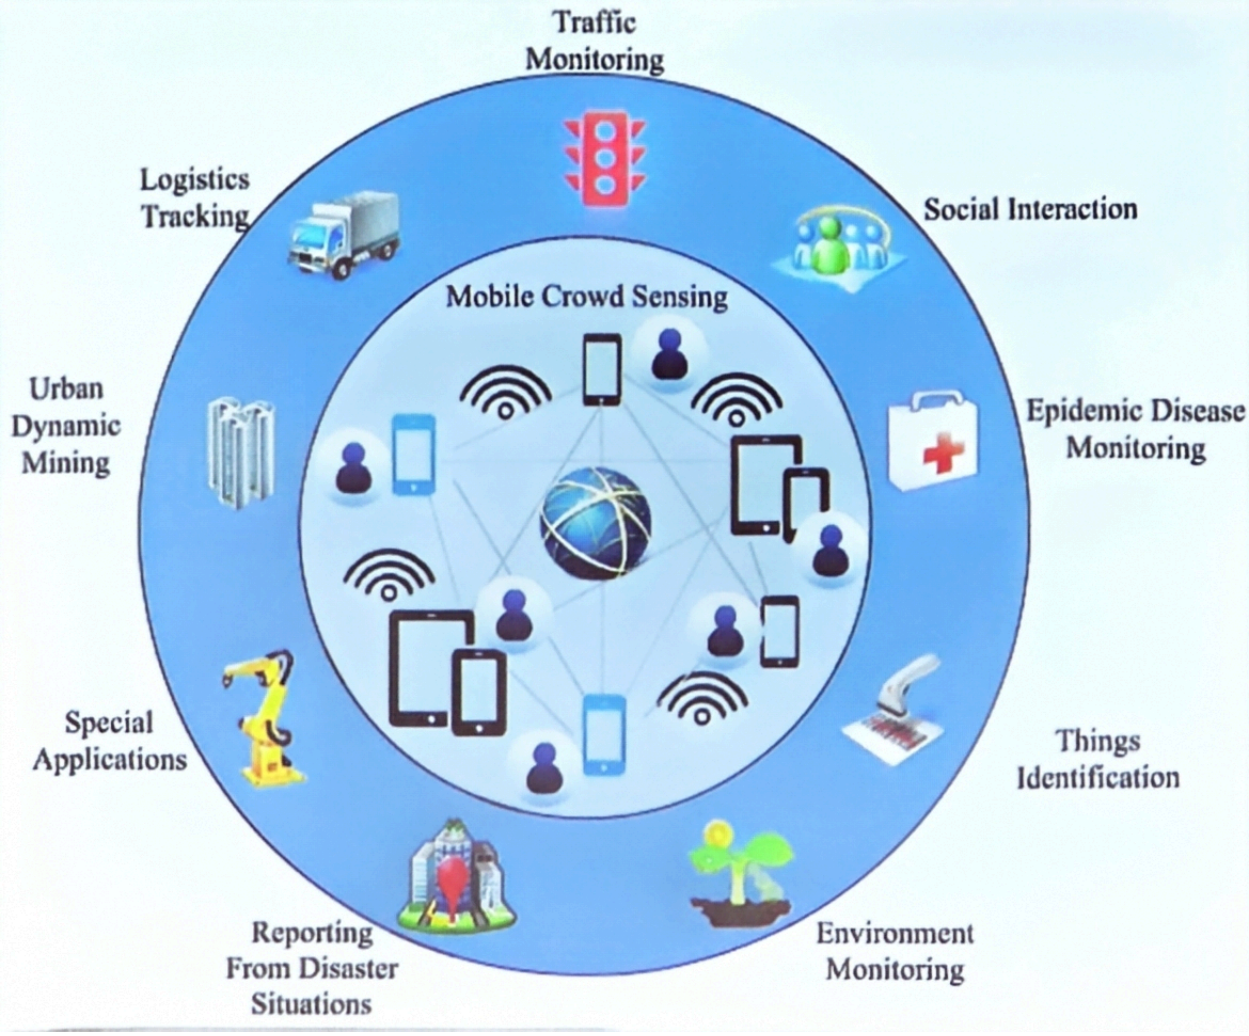

MCS 系統的基本角色

1. Service Provider 服務提供者

- 發布群眾感測任務
- 招募行動使用者
- 蒐集使用者回傳的資料
- 分析資料品質
- 計算獎勵與更新信譽值

2. Mobile Users 行動使用者 / Participants 參與者

- 接收任務
- 執行感測
- 回傳資料
- 消耗自身資源，例如電力、運算、儲存、頻寬

MCS 面臨的主要問題

1. 資源成本 Resource Costs

- 電池電量
- 運算能力
- 儲存空間
- 網路頻寬

2. 隱私風險 Privacy Risks

- 使用者位置
- 移動軌跡
- 工作地點
- 個人活動模式
- 行為資料

MCS Concerns

1. 資料可靠性 Reliable Data

MCS 系統需要足夠多使用者與可靠資料。

如果資料不完整、偽造或相似度異常，會影響系統分析結果。

2. 惡意使用者 Malicious Users

- 提供虛假資料
- 偽造使用者個人資料
- 試圖騙取獎勵
- 干擾資料品質判斷

MCS Incentives

> 使用者不會無條件參與 MCS 任務，除非系統能確保：

- 使用者的貢獻能被回報
- 系統具備可信任性
- 使用者的成本與風險能被補償

誘因機制的目的包括：

- 增加參與人數
- 加快任務分配
- 擴大服務覆蓋範圍
- 增加資料量
- 提升資料品質
- 讓使用者願意持續參與後續任務

常見的三種獎勵形式

1. Service Experience 服務經驗

使用者參與任務後，可以獲得較佳服務體驗。

- 更多功能權限
- 更好的服務品質
- 個人化服務

2. Reputation Credit 信譽點數

信譽點數用來代表使用者在 MCS 系統中的價值。

評估依據不只包含資料數量，也包含資料品質。

- 判斷使用者是否可信
- 決定使用者是否能繼續參與任務
- 決定未來獎勵高低

3. Monetary Token 金錢或虛擬代幣

金錢獎勵是補償使用者風險與資源消耗的方式。

但這類獎勵需要小心，因為金錢誘因可能吸引惡意使用者提供假資料以騙取報酬。

資料品質與可靠性監督方法

1. Data Trustworthiness 資料可信度

根據使用者屬性評估資料可信度

- 性別
- 年齡
- 位置
- 歷史行為

2. Personalized Task Assignment 個人化任務分配

根據使用者屬性與過去任務表現，分配較適合的任務。

3. Data Similarity 資料相似度

檢查不同使用者提供的資料是否與整體資料分布接近。

若某筆資料與大多數資料差距過大，可能代表資料不可靠。

4. Data Truthfulness 資料真實性

區分使用者類型

- 誠實使用者
- 自私使用者

- 惡意使用者

5. Data Cross-Validation 交叉驗證

由執行相同任務的使用者群體互相驗證資料品質。

MCS 中的經濟與賽局模型

1. Auction Theory

拍賣理論可描述服務提供者與使用者之間的交易關係。

- 誠實使用者可能以較低價格贏得任務
- 適合小規模使用者群體
- 但在大型 MCS 系統中不易擴展

2. Game Theory

賽局理論可以分析服務提供者與使用者之間的互相依賴與策略行為。

- 預測使用者策略
- 分析使用者是否參與任務
- 分析使用者如何回報資料
- 設計最佳獎勵策略

Stackelberg Game

- Leader 領導者：Service Provider 服務提供者
- Followers 跟隨者：Mobile Users 行動使用者

在 MCS 中：

1. 服務提供者決定任務與獎勵政策。
2. 使用者根據自己的成本、風險與獎勵決定是否參與。
3. 服務提供者根據使用者回傳資料調整後續獎勵與任務策略。

Incentive-G

Incentive-G 的目標

> 同時最大化服務提供者收益與所有使用者獎勵，並達到 Nash equilibrium。

- 服務提供者 revenue
- 使用者 rewards
- 資料品質
- 使用者信譽
- 惡意使用者防範

Incentive-G 的功能

Part 1：資料品質與信譽驗證

- 排除不完整資料
- 估計使用者資料價值
- 利用其他使用者投票判斷資料品質
- 降低惡意資料影響
- 給予有效貢獻者合理獎勵

Part 2：兩階段 Stackelberg 賽局

- 分析使用者是否參與
- 預測使用者策略
- 調整獎勵政策
- 達成 Nash equilibrium
- 最大化服務提供者收益與使用者獎勵

Incentive-G 的流程

Step 1：Accomplishing Crowdsensing Tasks

服務提供者通知使用者：

- 任務內容
- 預期獎勵
- 任務要求

使用者根據自身條件判斷是否接受任務，例如：

- 處理成本
- 風險
- 預期獎勵

若接受任務，使用者會回傳感測資料。

Step 2：Analyzing Sensing Data

服務提供者將蒐集到的資料視為一種資料分布，並觀察使用者資料與整體分布的差異。

- 衡量資料品質
- 排除不完整資料
- 判斷資料是否與其他資料過度偏離

Step 3：Updating Reputation Values

根據使用者過去參與紀錄與目前資料品質，更新其 reputation score。

更新信譽的依據包含：

- 歷史任務表現
- 資料品質
- 其他使用者投票結果

Step 4：Updating Rewards for Users

服務提供者根據：

- 資料品質
- 使用者信譽

- 投票分數
- Stackelberg game 結果

計算每位使用者的最佳獎勵，使使用者願意繼續參與 MCS 任務。

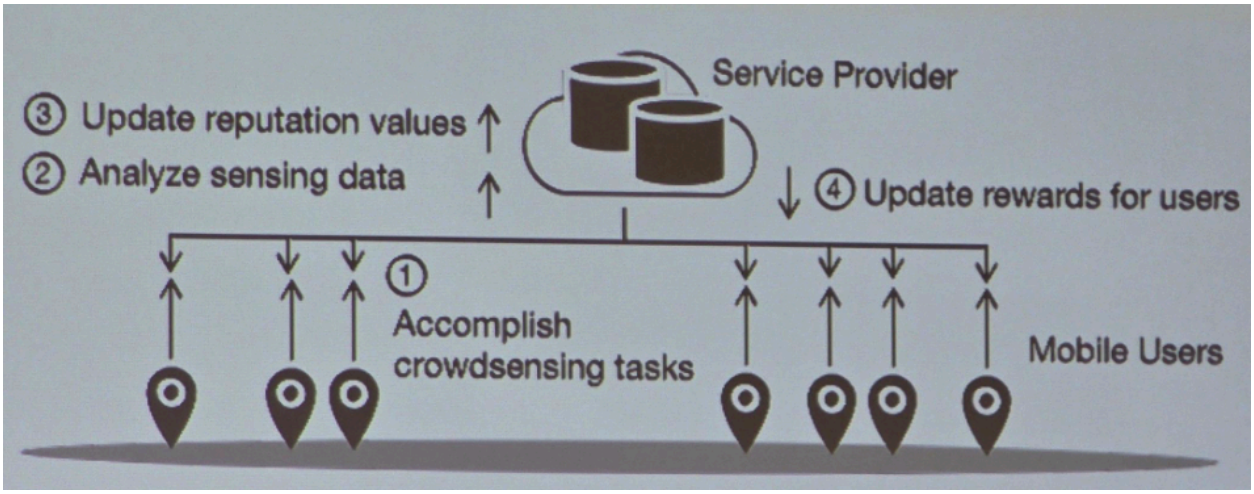

Incentive-G Part 1：資料品質監督

1. Data Screening 資料篩選

系統會檢查使用者提供的資料是否達到最低門檻。

若資料符合門檻，系統才會接收該資料。

2. Data Similarity 資料相似度

系統使用 **Chebyshev distance** 衡量兩筆資料之間的相似度。

用途：

- 判斷資料是否偏離整體資料分布
- 衡量資料與 centroid 中心點的距離
- 找出可能異常或不可靠的資料

3. Reputation analysis 信譽分析

系統會為使用者計算 reputation score。

1. **Historical behavior 歷史行為**

2. **Voting score 投票分數**

也就是：

- 使用者過去任務表現越好，信譽越高
- 其他使用者對其資料品質評價越高，信譽越高

4. Reward Measure 獎勵衡量

為了保持公平獎勵政策，獎勵函數會納入 voting score。

- 若使用者資料本身可能被偽造，投票分數可以降低負面影響
- 有助於辨識不可靠資料
- 可以讓獎勵更公平
- 可以抑制惡意使用者

Incentive-G Part 2：Two-stage Stackelberg Game

使用兩階段 Stackelberg game 來解釋使用者行為與誘因效果。

系統關係

- 服務提供者是 leader
- 使用者是 followers

互動流程

1. 服務提供者決定獎勵政策並分配任務。
2. 使用者根據獎勵、成本與風險決定是否參與。
3. 服務提供者收到資料後，觀察使用者策略。
4. 服務提供者調整下一輪任務的獎勵與交換機制。
5. 系統同時對惡意使用者進行資料品質監督與懲罰。

最佳化目標

- 最大服務提供者收益
- 最大使用者獎勵

- Stackelberg game 的 Nash equilibrium

Comparison

1. QnQ 方法

> 使用者貢獻不只看資料量，也看資料品質與可信度。

它根據：

- 使用者可信度 user trustworthiness
- 資料品質 data quality
- 資料數量 quantity

來計算使用者的 reputation score。

但它相較於 Incentive-G，較缺乏完整的 voting validation 與整合式獎勵調整設計。

2. Social 方法

> 它會參考使用者在社群網路中的 social effects，也就是使用者之間的社會關係或互動影響。

- 考慮社交網路影響
- 使用 Stackelberg game 分配任務
- 主要目標偏向服務提供者收益最大化

但相較於 Incentive-G，它對資料品質、惡意使用者與投票驗證的處理較不完整。

3. WoM 方法

> **Word of Mouth** 使用 self-organized teamwork，也就是讓使用者自組團隊來維持感測資料的品質與數量。

- 強調團隊合作
- 透過團隊維持資料品質與數量
- 也使用 Stackelberg game 模型

但它比較偏向團隊互動與任務合作，對個別使用者的資料驗證與惡意行為懲罰不如 Incentive-G 明確。

4. Auction 方法

> Auction 方法基於 bid-auction architecture，也就是競標架構。

流程：

1. 服務提供者為每個任務發布 auction。
2. 使用者對任務出價。
3. 系統通常優先考慮較低價格的使用者。
4. 服務提供者再利用 reputation-based incentive 避免惡意使用者參與。

優點：

- 可以降低服務提供者支付成本
- 使用者透過競標方式取得任務
- 適合任務明確、使用者數量可控的情境

缺點：

- 可能過度偏向低價使用者
- 若只看低價，可能犧牲資料品質
- 需要搭配信譽機制避免惡意使用者低價搶任務

Sensitivity Analysis

- baseline: $|P| = 500, \mu=1,$

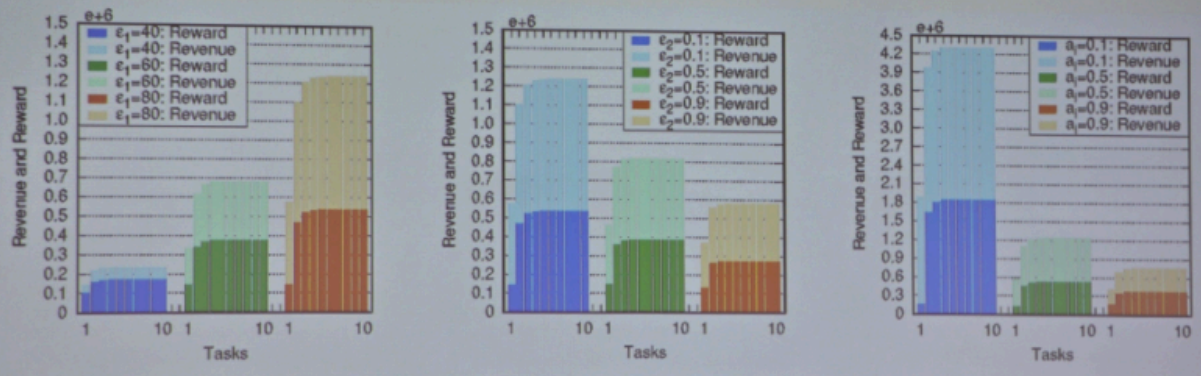

(a) Variance of ε_1 (ε_2=0.1 and a_i=0.5) (b) Variance of ε_2 (ε_1=80 and a_i=0.5) (c) Variance of a_i (ε_1=80 and ε_2=0.1)